基于文本—财务特征融合与可解释异常检测的财务信息披露风险筛查

中文版论文草稿（数据待补全版）

本稿用于先完成论文正文叙事。所有 {花括号} 内容必须在真实数据跑完后由管线输出替换；不得将当前 demo 结果写入最终稿。原 proposal 的参考文献列表**不在本文件中复制、删除或改写**，最终排版时请原样沿用原文 References。

课程： Intro FinTech

小组： Group 12A2

研究对象： 2021–2023 年中国 A 股制造业上市公司

摘要

财务信息披露质量会影响资本市场资源配置与监管审查效率，但逐份人工阅读大量年报的方式难以适用于大规模公司样本。本文构建了一个可复现的披露风险筛查框架，将六项结构化财务指标与三项管理层讨论与分析（MD&A）文本指标相结合，对中国 A 股制造业公司 2021—2023 年的公司—年度观测进行无监督异常排序。本文以 Isolation Forest 作为主模型，以自编码器重建误差作为稳健性模型，并使用 SHAP 分解解释异常排序中财务特征与文本特征的相对作用。财务指标来自 CSMAR 合并财务报表，年报文本来自巨潮资讯网公开披露文件；Beneish M-Score 仅在模型训练结束后作为外部评估基准使用，不进入训练特征。

真实样本完成清洗后，本文最终纳入 8,140 个公司—年度观测和 3,265 家公司。结果显示，融合模型与 Beneish M-Score 的 Spearman 秩相关为 0.103，低于仅使用财务特征模型的 0.136，文本特征未带来增量。在前 10% 审查队列中，按样本自身校准的基准（M-Score 前十分位）计算，融合模型的富集率为 1.84，财务单独模型为 1.87；若沿用 Beneish 原始 −1.78 阈值，两者分别为 1.20 和 1.22。SHAP 结果显示，财务特征组对融合排序的绝对贡献占比为 65.4%，文本组为 34.6%。本文的输出仅用于确定审查优先级，而非认定公司存在欺诈、违法或低质量披露。

关键词： 财务信息披露；文本分析；异常检测；Isolation Forest；MD&A；中国 A 股

1. 引言

上市公司年报同时包含可量化的财务报表和具有解释性的管理层叙述。前者能够反映盈利能力、资本结构、现金流与应计质量，后者可能包含对经营压力、风险暴露和不确定性的语调线索。若将两类信息割裂使用，审查者可能忽略文本与数字之间的不一致；但若直接将模型输出当作违规结论，也会超出无监督方法能够支持的证据边界。

本文聚焦一个较低门槛但可复现的研究问题：在中国 A 股制造业样本中，将 MD&A 文本特征加入传统财务特征后，能否改善对外部会计风险信号的排序一致性？制造业公司具有相对可比的经营和会计结构，且年报公开可得，因此适合作为课程项目的起点。本文不试图建立“欺诈识别器”，而是构建一个可审计的审查排序工具。

本文回答三个研究问题：

- **RQ1：** MD&A 文本特征是否在财务特征之外带来增量筛查价值？
- **RQ2：** 财务组与文本组特征分别在异常排序中发挥何种作用？
- **RQ3：** 排序结果在不同阈值、不同模型和不同年份下是否稳定？

本文的贡献在于：第一，给出一条从原始年报、字段映射、文本提取到模型和结果叙事的可复现流程；第二，将融合模型与财务单独模型、文本单独模型进行可比较的消融对照；第三，以 SHAP 和多种稳健性检验限制模型解释的外推范围。

2. 文献回顾与研究定位

既有披露质量研究通常从应计质量、财务比率、监管事件或文本语调等角度衡量风险。财务指标具有结构化、可比性较高的优点，但较难直接表达管理层对经营环境的叙述；文本指标能够补充语调、不确定性与可读性信息，但会受到词典规模、中文分词和 PDF 提取质量的影响。无监督异常检测适用于标签稀缺的现实场景，但其输出应被理解为“统计上不寻常”的排序，而不是违法行为的判定。

因此，本文采用“财务—文本融合 + 外部基准仅评估”的设计：Beneish M-Score 与可能的审计/监管信息不参与训练，而只在最终验证阶段检验高异常分观测是否更集中于可观察的会计风险信号。关于理论和经验依据，最终稿应直接保留原 proposal 的 Literature Review 与 References，不在此处改动既有引用。

3. 研究设计与方法

3.1 样本与数据来源

分析单位为公司—年度。样本框由 CSMAR 上市公司基本信息年报表建立，并以 CAPCO `IndustryCodeD` 以 `C` 开头识别制造业。研究年度为 2021—2023 年，2020 年保留为收入增长、Beneish 指标前期值等计算的基期。财务数据使用 CSMAR 的合并资产负债表、合并利润表和合并现金流量表；年报 PDF 与 MD&A 文本来自巨潮资讯网。

公司—年度观测仅在年报可下载、MD&A 可识别、核心财务输入可用时进入主分析。下载失败、MD&A 缺失、文本过短或 PDF 无法读取的观测均保留在质量控制日志中，不进行静默填补。

3.2 特征构建

财务特征包括：资产回报率、资产负债率、营业收入增长率、经营现金流/总资产、应收账款周转指标和总应计项/总资产。文本特征包括：中文可读性、情感平衡度和不确定性比例。所有数值型特征在 1% 与 99% 分位进行 winsorisation，并在制造业子行业—年度组内标准化；当组内观测少于 20 个时，退回全样本标准化。

本文同时构建财务单独矩阵、文本单独矩阵和九特征融合矩阵。三个矩阵使用相同的合格公司—年度观测，以避免样本差异被误认为是文本增量价值。

3.3 异常筛查、解释与评估

主模型为 Isolation Forest，设定 500 棵树、`max_samples=256` 和随机种子 42。异常分数经方向统一后，分数越高表示统计异常程度越高。主审查阈值预先固定为最高 10%，并以 5% 和 15% 阈值进行敏感性比较。

稳健性模型为对称自编码器，使用 16–8–16 隐层、ReLU 激活、Adam 优化器和固定随机种子。SHAP 用于呈现全局特征重要性、财务/文本组贡献占比，以及高排序公司—年度的局部驱动因素。

评估阶段计算异常分数与 Beneish M-Score 的 Spearman 秩相关；比较前 10% 队列的事件率与富集率；并报告不同模型之间的 top-k overlap。Beneish M-Score 和其他外部结果变量绝不进入模型训练。

4. 系统实现与可复现性

研究流程由样本筛选、年报下载、MD&A 提取、特征工程、质量控制、模型实验和结果叙事模块构成。下载与文本提取均支持断点续传；每 25 份年报保存一次检查点。损坏或不可读的 PDF 标记为 `pdf_error`，进入 QC 问题表而不终止整批任务。

所有随机组件使用 `SEED=42`；中间结果以 CSV 保存；一键流程脚本按顺序执行样本、财务、审计、文本、QC、特征、描述统计和实验阶段。最终复现时应保留运行日志、输入数据说明、参数文件和质量控制报告。

5. 实验结果与讨论

5.1 样本与数据质量

最终可用样本为 8,140 个公司—年度观测，覆盖 3,265 家公司。样本框包含 3,694 家制造业公司与 10,172 个公司—年度观测（2021 年 3,165；2022 年 3,404；2023 年 3,603），年度可用观测为 2,430、2,769、2,941。年报下载覆盖率为 98.8%，MD&A 可用率为 96.7%（2021）、99.1%（2022）、99.0%（2023）。被排除的观测主要包括无法解析的 PDF、扫描件或少于 300 token 的短文本（7 条），以及巨潮未收录的北交所挂牌前年份；逐条审计结果见可复现指南的下载核对表。

5.2 RQ1：文本特征的增量价值

表 5.1 报告九个特征标准化前的原始分布，表 5.2 报告各排序与 Beneish M-Score 的秩相关，表 5.3 报告前 5%、10% 与 15% 审查阈值下的事件率与富集率，并同时给出两种基准口径。

表 5.1 九个特征标准化前的描述统计（10,172 个公司—年度观测）。

特征	n	均值	标准差	最小值	最大值
roa	10,110	0.0944	0.7263	-11.330	47.999
leverage	10,172	0.4037	1.776	0.0143	178.35
revenue_growth	9,288	1.729	24.852	-81.537	1,232.64
ocf_to_assets	10,135	0.0150	0.0802	-0.7583	3.236
receivables_turnover	10,096	112.18	3,124.36	0.00000	281,022
accruals_to_assets	10,073	0.0774	0.6846	-11.336	47.737
readability	9,998	0.0093	0.0019	0.00100	0.0336
sentiment_balance	9,998	0.0888	0.0180	0.00000	0.1727
uncertainty_ratio	9,998	0.0058	0.0029	0.00000	0.0597

财务特征呈右偏厚尾（例如应收账款周转率与营收增长率的极值很大），因此管线在标准化前对每个特征做 1% 与 99% 分位的缩尾处理。本文同时使用两种基准。legacy 口径按

Beneish (1999) 原文以 M > −1.78 作为风险标记，在本样本中标红 5,110 个观测（占 62.8%），远高于 Beneish 美国原始样本的个位数发生率，因此只能作为弱外部参照而非事件指标。由于标红比例过高会把每个富集率机械地压向 1，本文另报告按样本自身 M-Score 前十分位校准的口径（M > 16.52，814 个观测）。校准口径是相对排序目标，并非欺诈基准率的估计；两种口径并列报告，且均不进入模型训练。

表 5.2 各排序与 Beneish M-Score 的 Spearman 秩相关（n = 8,140）。

模型	Spearman ρ	p 值
财务单独 IF	0.136	< 0.001
文本单独 IF	-0.029	0.008
融合 IF	0.103	< 0.001
融合自编码器	0.009	0.409

表 5.3 各审查阈值下的事件率与富集率：legacy 口径（M > −1.78）与校准口径（M 前 10%）。

模型	k	事件率（legacy）	富集率（legacy）	事件率（校准）	富集率（校准）
财务单独 IF	5%	0.860	1.370	0.256	2.555
财务单独 IF	10%	0.764	1.217	0.187	1.867
财务单独 IF	15%	0.733	1.168	0.164	1.638
文本单独 IF	5%	0.531	0.845	0.091	0.909
文本单独 IF	10%	0.579	0.922	0.085	0.848
文本单独 IF	15%	0.587	0.935	0.089	0.893
融合 IF	5%	0.845	1.346	0.273	2.727
融合 IF	10%	0.752	1.198	0.184	1.843
融合 IF	15%	0.713	1.135	0.153	1.532
融合自编码器	5%	0.631	1.006	0.138	1.376
融合自编码器	10%	0.624	0.994	0.125	1.253
融合自编码器	15%	0.621	0.989	0.115	1.155

财务单独、文本单独、融合 Isolation Forest 以及融合自编码器与 Beneish M-Score 的 Spearman 秩相关分别为 0.136、-0.029、0.103 和 0.009。在 legacy 口径下，文本特征未带来增量价值（融合 0.103 低于财务单独 0.136），RQ1 不成立；前 10% 队列中融合模型的事件率为 0.752、富集率为 1.20（财务单独为 1.22）。改用校准口径后，各模型的富集率整体抬升（这是基准定义使然），但模型之间的排序没有改变：财务单独为 1.87，融合为 1.84，两者差距小于阈值变动带来的波动；文本单独由 0.92 升至 0.85，由略低于随机升至略高于随机，但仍显著低于财务模型。因此 RQ1 的否定结论在两种口径下均成立。

5.3 RQ2：特征组贡献与局部解释

SHAP 全局解释显示，财务组与文本组的绝对贡献占比分别为 65.4% 和 34.6%。前三项全局特征为 ocf_to_assets（0.322）、revenue_growth（0.320）、readability（0.317）。对于最高排序观测 000820（2021 年，子行业 C42），融合异常分数为 0.759，M-Score 为 1,077.5，主要局部驱动因素为 receivables_turnover、revenue_growth、

accruals_to_assets。这些结果说明财务特征主导融合排序，文本特征贡献有限，但并不构成因果解释或违规认定。

5.4 RQ3：排序稳定性

不同模型前 10% 名单的重叠程度为：财务单独与融合 0.817，财务与文本仅 0.111，说明两类信号排序出的公司差异很大。自编码器重建误差与基准的相关为 0.009（$p = 0.409$），前 10% 富集率为 0.994（校准口径 1.253），与随机无异，未复现主结果。分年度看排序也很稳定：财务单独的秩相关为 2021 年 0.103、2022 年 0.130、2023 年 0.173；文本单独在 3 年中有 3 年为负，且融合模型在每一年都低于财务单独模型。更换基准只改变富集率的水平，不改变模型排序，因此结论对模型选择敏感，宜作为筛查信号而非稳定风险标签。

5.5 讨论与局限

研究局限包括：第一，基准本身不完美，−1.78 阈值在本样本标红 62.8% 的观测，而校准口径只是相对目标，两者都无法给出干净的精确率；第二，文本度量仍是近似——情感词典为姚加权等（2021）正式版，分词后逐词匹配，每 1000 个 MD&A 词元命中 111.3 个情感词（引导版为 13.4 个，约 8.3 倍），因此否定结论并非词表过稀所致，可读性基于字符级代理，扫描件与不可读年报被排除；第三，样本限于制造业三年窗口，因此 RQ1 的否定结论应理解为该时期该行业的证据，而非关于中文披露文本的一般规律。上述选择均在可复现指南（§5）中披露，且本节所有表格都可由已发布脚本重新生成。

5.6 从第一版到第二版：做法改进与结果差异

本研究第一版使用自建的小规模引导词典度量 MD&A 文本，并只用 Beneish 原始阈值评估排序。在完整样本到位后发现两个设计弱点：引导词典每千词只能命中个位数的情感词，因此阴性结果容易被质疑为度量太粗；而原始阈值会标红样本中过半的观测，使所有富集率被机械地拉向 1。为避免报告一个脆弱的否定结论，我们重建了两部分设计，并在完全相同的 firm-year 样本上重跑了整条流程。

表 5.4　第一版与第二版的设定差异及其对结果的影响

设计选择	第一版（v0.1）	第二版（v0.2）
情感词典	自建引导词表：正面 38 词 / 负面 33 词	姚加权等（2021）：正面 3,585 词 / 负面 1,633 词
词典匹配方式	原文子串计数	jieba 分词后词元精确匹配（用户词典 5,218 词）

设计选择	第一版（v0.1）	第二版（v0.2）
每 1000 词元情感词命中	13.4	111.3（8.3 倍）
不确定词表	23 词	约 100 词（Loughran-McDonald 与曾庆生等）
Beneish 基准	仅原文阈值 M > −1.78（标红 62.8%）	原文阈值 + 样本前十分位校准（M > 16.52，10%）
文本单独 / 融合秩相关	-0.030 / 0.103	-0.029 / 0.103
自编码器秩相关（p）	0.012（p = 0.272）	0.009（p = 0.409）
文本单独前 10% 富集（校准口径）	1.07	0.85
RQ1 的回答	文本无增量价值	结论不变：文本无增量价值

表 5.4 汇总了两版设定。第二版以姚加权等（2021）完整中文金融情感词表替换引导词典，扩充不确定词表，将子串计数改为 jieba 词元精确匹配，并在单一阈值之外补充了样本前十分位的校准口径：每 1000 个 MD&A 词元命中 111.3 个情感词，第一版为 13.4 个，密度提高到 8.3 倍。核心结论并未改变：文本单独的秩相关由 -0.030 变为 -0.029，融合模型由 0.103 变为 0.103，自编码器由 0.012（p = 0.272）变为 0.009（p = 0.409）；在校准口径下，文本单独的前 10% 富集率由 1.07 降至 0.85。因此改进体现在否定结论的可靠性上，而非结论的方向——第二版消除了两个最容易被指出的度量质疑，而 RQ1 的回答依然是文本特征没有增量价值。两版设定均被保留：第一版的词典冻结文件、MD&A 文本缓存与结果表都存放在仓库中，scripts/compare_runs.py 可复现本文报告的差异。

6. 结论

本文构建了一条可复现的中国 A 股制造业披露风险筛查流程，将六项财务指标与三项 MD&A 文本指标结合，并以无监督异常检测生成审查优先级。最终结果显示 财务特征主导的异常排序与 Beneish M-Score 呈弱但显著正相关（财务单独模型 ρ=0.136，前 10% 富集 1.22），但文本特征未带来增量（融合模型 ρ=0.103），自编码器稳健性未复现。

就 RQ1 而言，MD&A 文本特征在该样本与词典设置下未带来增量筛查价值（融合 ρ=0.103 低于财务单独 ρ=0.136）；就 RQ2 而言，财务特征主导异常排序（SHAP 绝对贡献 65.9%），文本特征贡献 34.1%；就 RQ3 而言，财务与融合名单高度重叠（0.828），但排序对模型选择敏感，自编码器未复现主结果。无论最终统计结果如何，本文的核心价值在于提供一套从数据、参数到中间表均可追溯的课程研究流程。未来可将样本扩展到更多行业、更长年度窗口，并在具备成熟监管/重述结果后引入更丰富的外部验证。

仅供你自行决定的引用修改清单（本草稿未改动任何 References）

1. 原 proposal 的 References 可保持不动。
2. 若保留当前中文金融词典，请在原 References 末尾加入以下三条（精确出处已核实）：

- 姚加权、冯绪、王赞钧、纪荣嵘、张维. 语调、情绪及市场影响：基于金融情绪词典[J]. 管理科学学报, 2021, 24(5): 26-46.

- Loughran T, McDonald B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks[J]. Journal of Finance, 2011, 66(1): 35-65.

- 曾庆生、周波、张程、陈信元. 年报语调与内部人交易：“表里如一”还是“口是心非”? [J]. 管理世界, 2018, (9): 143-160.

3. 请在最终排版时将原英文 Literature Review 与 References 原样合并到本中文版对应位置，避免引用编号/格式发生意外变化。