基于文本—财务特征融合与可解释异常检测的财务信息披露风险筛查

中文版论文草稿（数据待补全版）

本稿用于先完成论文正文叙事。所有 {花括号} 内容必须在真实数据跑完后由管线输出替换；不得将当前 demo 结果写入最终稿。原 proposal 的参考文献列表**不在本文件中复制、删除或改写**，最终排版时请原样沿用原文 References。

课程： Intro FinTech

小组： Group 12A2

研究对象： 2021–2023 年中国 A 股制造业上市公司

摘要

财务信息披露质量会影响资本市场资源配置与监管审查效率，但逐份人工阅读大量年报的方式难以适用于大规模公司样本。本文构建了一个可复现的披露风险筛查框架，将六项结构化财务指标与三项管理层讨论与分析（MD&A）文本指标相结合，对中国 A 股制造业公司 2021—2023 年的公司—年度观测进行无监督异常排序。本文以 Isolation Forest 作为主模型，以自编码器重建误差作为稳健性模型，并使用 SHAP 分解解释异常排序中财务特征与文本特征的相对作用。财务指标来自 CSMAR 合并财务报表，年报文本来自巨潮资讯网公开披露文件；Beneish M-Score 仅在模型训练结束后作为外部评估基准使用，不进入训练特征。

真实样本完成清洗后，本文最终纳入 8,140 个公司—年度观测和 3,265 家公司。结果显示，融合模型与 Beneish M-Score 的 Spearman 秩相关为 0.103，相较仅使用财务特征的模型 0.136，文本特征未带来增量（融合 0.103 低于财务单独 0.136）。在前 10% 审查队列中，M-Score 风险事件率为 0.738，富集率为

1.176。SHAP 结果进一步表明，财务特征组 对融合排序的绝对贡献占比更高。本文的输出仅用于确定审查优先级，而非认定公司存在欺诈、违法或低质量披露。

关键词： 财务信息披露；文本分析；异常检测；Isolation Forest；MD&A；中国 A 股

1. 引言

上市公司年报同时包含可量化的财务报表和具有解释性的管理层叙述。前者能够反映盈利能力、资本结构、现金流与应计质量，后者可能包含对经营压力、风险暴露和不确定性的语调线索。若将两类信息割裂使用，审查者可能忽略文本与数字之间的不一致；但若直接将模型输出当作违规结论，也会超出无监督方法能够支持的证据边界。

本文聚焦一个较低门槛但可复现的研究问题：在中国 A 股制造业样本中，将 MD&A 文本特征加入传统财务特征后，能否改善对外部会计风险信号的排序一致性？制造业公司具有相对可比的经营和会计结构，且年报公开可得，因此适合作为课程项目的起点。本文不试图建立“欺诈识别器”，而是构建一个可审计的审查排序工具。

本文回答三个研究问题：

- **RQ1：** MD&A 文本特征是否在财务特征之外带来增量筛查价值？
- **RQ2：** 财务组与文本组特征分别在异常排序中发挥何种作用？
- **RQ3：** 排序结果在不同阈值、不同模型和不同年份下是否稳定？

本文的贡献在于：第一，给出一条从原始年报、字段映射、文本提取到模型和结果叙事的可复现流程；第二，将融合模型与财务单独模型、文本单独模型进行可比较的消融对照；第三，以 SHAP 和多种稳健性检验限制模型解释的外推范围。

2. 文献回顾与研究定位

既有披露质量研究通常从应计质量、财务比率、监管事件或文本语调等角度衡量风险。财务指标具有结构化、可比性较高的优点，但较难直接表达管理层对经营环境的叙述；文本指标能够补充语调、不确定性与可读性信息，但会受到词典规模、中文分词和 PDF 提取质量的影响。无监督异常检测适用于标签稀缺的现实场景，但其输出应被理解为“统计上不寻常”的排序，而不是违法行为的判定。

因此，本文采用“财务—文本融合 + 外部基准仅评估”的设计：Beneish M-Score 与可能的审计/监管信息不参与训练，而只在最终验证阶段检验高异常分观测是否更集中于可观察的会计风险信号。关于理论和经验依据，最终稿应直接保留原 proposal 的 Literature Review 与 References，不在此处改动既有引用。

3. 研究设计与方法

3.1 样本与数据来源

分析单位为公司—年度。样本框由 CSMAR 上市公司基本信息年报表建立，并以 CAPCO `IndustryCodeD` 以 `C` 开头识别制造业。研究年度为 2021—2023 年，2020 年保留为收入增长、Beneish 指标前期值等计算的基期。财务数据使用 CSMAR 的合并资产负债表、合并利润表和合并现金流量表；年报 PDF 与 MD&A 文本来自巨潮资讯网。

公司—年度观测仅在年报可下载、MD&A 可识别、核心财务输入可用时进入主分析。下载失败、MD&A 缺失、文本过短或 PDF 无法读取的观测均保留在质量控制日志中，不进行静默填补。

3.2 特征构建

财务特征包括：资产回报率、资产负债率、营业收入增长率、经营现金流/总资产、应收账款周转指标和总应计项/总资产。文本特征包括：中文可读性、情感平衡度和不确定性比例。所有数值型特征在 1% 与 99% 分位进行 winsorisation，并在制造业子行业—年度组内标准化；当组内观测少于 20 个时，退回全样本标准化。

本文同时构建财务单独矩阵、文本单独矩阵和九特征融合矩阵。三个矩阵使用相同的合格公司—年度观测，以避免样本差异被误认为是文本增量价值。

3.3 异常筛查、解释与评估

主模型为 Isolation Forest，设定 500 棵树、`max_samples=256` 和随机种子 42。异常分数经方向统一后，分数越高表示统计异常程度越高。主审查阈值预先固定为最高 10%，并以 5% 和 15% 阈值进行敏感性比较。

稳健性模型为对称自编码器，使用 16–8–16 隐层、ReLU 激活、Adam 优化器和固定随机种子。SHAP 用于呈现全局特征重要性、财务/文本组贡献占比，以及高排序公司—年度的局部驱动因素。

评估阶段计算异常分数与 Beneish M-Score 的 Spearman 秩相关；比较前 10% 队列的事件率与富集率；并报告不同模型之间的 top-k overlap。Beneish M-Score 和其他外部结果变量绝不进入模型训练。

4. 系统实现与可复现性

研究流程由样本筛选、年报下载、MD&A 提取、特征工程、质量控制、模型实验和结果叙事模块构成。下载与文本提取均支持断点续传；每 25 份年报保存一次检查点。损坏或不可读的 PDF 标记为 `pdf_error`，进入 QC 问题表而不终止整批任务。

所有随机组件使用 SEED=42；中间结果以 CSV 保存；一键流程脚本按顺序执行样本、财务、审计、文本、QC、特征、描述统计和实验阶段。最终复现时应保留运行日志、输入数据说明、参数文件和质量控制报告。

5. 实验结果与讨论

5.1 样本与数据质量

最终可用样本为 8,140 个公司—年度观测，覆盖 3,265 家公司。年报下载覆盖率为 98.8%；MD&A 可用率为 96.5%–99.0%。被排除的观测主要包括 无法解析的 PDF、扫描件或少于 300 token 的短文本，以及巨潮未收录的北交所挂牌前年份，其数量和年度分布见 表 5.1。

5.2 RQ1：文本特征的增量价值

财务单独、文本单独、融合 Isolation Forest 以及融合自编码器与 Beneish M-Score 的 Spearman 秩相关分别为 0.136、−0.030、0.103 和 0.012。因此，文本特征未带来增量价值（融合 0.103 低于财务单独 0.136），RQ1 不成立。在前 10% 审查队列中，融合模型的事件率为 0.738，富集率为 1.176，说明其 提供弱但正向的筛查信号（事件率为全样本基准的 1.18 倍）。

5.3 RQ2：特征组贡献与局部解释

SHAP 全局解释显示，财务组与文本组的绝对贡献占比分别为 65.9% 和 34.1%。前三项全局特征为 经营现金流/总资产（0.324）、营收增长率（0.317）、可读性（0.315）。对于最高排序观测 000820（2021 年，子行业 C42），主要局部驱动因素为 应收账款周转率、营收增长率、经营现金流/总资产。这些结果说明 财务特征主导融合排序，文本特征贡献有限，但并不构成因果解释或违规认定。

5.4 RQ3：排序稳定性

不同模型前 10% 名单的重叠程度为 财务单独与融合名单 0.828，财务与文本仅 0.120；5%、10% 和 15% 阈值下的事件率与富集率见 表 5.3。自编码器结果 自编码器重建误差与基准无显著相关（ρ=0.012，p=0.272），未复现主结果。因此，排序在 不同模型与阈值 范围内呈现 对模型选择敏感，宜作为筛查信号而非稳定风险标签。

5.5 讨论与局限

若融合模型优于财务单独模型，可将其解释为 MD&A 叙述提供了额外的排序信息；若未优于，则应如实报告文本特征在该样本和词典设置下未带来增益。研究局限包括：样本限于制造业和三年窗口；词典为引导版；PDF 提取存在异质性；Beneish M-Score 是不完美的外部信号。因而，模型结果只能服务于人工复核的排序，而不能证明欺诈、违法或披露质量低下。

6. 结论

本文构建了一条可复现的中国 A 股制造业披露风险筛查流程，将六项财务指标与三项 MD&A 文本指标结合，并以无监督异常检测生成审查优先级。最终结果显示财务特征主导的异常排序与 Beneish M-Score 呈弱但显著正相关（财务单独模型 ρ=0.136，前 10% 富集 1.22），但文本特征未带来增量（融合模型 ρ=0.103），自编码器稳健性未复现。

就 RQ1 而言，MD&A 文本特征在该样本与词典设置下未带来增量筛查价值（融合 ρ=0.103 低于财务单独 ρ=0.136）；就 RQ2 而言，财务特征主导异常排序（SHAP 绝对贡献 65.9%），文本特征贡献 34.1%；就 RQ3 而言，财务与融合名单高度重叠（0.828），但排序对模型选择敏感，自编码器未复现主结果。无论最终统计结果如何，本文的核心价值在于提供一套从数据、参数到中间表均可追溯的课程研究

流程。未来可将样本扩展到更多行业、更长年度窗口，并在具备成熟监管/重述结果后引入更丰富的外部验证。

仅供你自行决定的引用修改清单（本草稿未改动任何 References）

1. 原 proposal 的 References 可保持不动。
2. 若保留当前中文金融词典，请在原 References 末尾加入以下三条（精确出处已核实）：

- 姚加权、冯绪、王赞钧、纪荣嵘、张维. 语调、情绪及市场影响：基于金融情绪词典[J]. 管理科学学报, 2021, 24(5): 26-46.

- Loughran T, McDonald B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks[J]. Journal of Finance, 2011, 66(1): 35-65.

- 曾庆生、周波、张程、陈信元. 年报语调与内部人交易：“表里如一”还是“口是心非”？[J]. 管理世界, 2018, (9): 143-160.

3. 请在最终排版时将原英文 Literature Review 与 References 原样合并到本中文版对应位置，避免引用编号/格式发生意外变化。