4. 系统实现与模型开发

4.1 流程概览与可复现性

第三章描述了我们计划做什么；本章则说明到目前为止实际构建了什么以及它是如何工作的。整个研究是以一组有顺序的 Python 脚本实现的，而不是一个大的程序。每个脚本只有一项明确的工作：读取一个输入文件、执行一个步骤、写出一个输出文件。这样系统更容易检查、更容易调试，也更容易让别人重新运行。脚本按功能分到几个文件夹里，分别负责数据获取、特征构建、模型和报告，职责划分得很清楚。

整个流程按固定顺序经过八个主要阶段。第一，从 CSMAR 基本信息表构建样本。第二，把三张财务报表解析成一张中间表。第三，把下载的年报文件与样本清单核对。第四，从每个 PDF 里提取管理层讨论与分析（MD&A）文本。第五，生成质量控制报告，标出缺失或异常记录。第六，把财务特征和文本特征合并成一张特征表。第七，用描述性统计概括样本。第八，运行模型并把结果转写成可读的报告。一个脚本就能跑完整条链，每个阶段也可以单独运行，便于只重复流程中的某一部分。

可复现性被当作头等要求，而不是事后补上的东西。每个随机过程都用同一个固定种子（42），所以在同样的数据上重复运行会得到同样的数字。所有参数都写在一个配置文件里，所有中间结果都保存为可以直接查看的 CSV 文件。代码有自动化测试覆盖，目前有七十多个测试，全部通过。

4.2 数据获取与质量控制

样本来自 CSMAR 的上市公司基本信息年报表。我们只保留制造业公司，用行业代码以字母“C”开头来识别，并保留研究年份 2021、2022 和 2023。2020 年也保留作为基期年，因为有些特征（比如营收增长率和 Beneish M-Score）需要上一年的数字。筛选后，样本大约有 3,700 家公司和约 10,000 个公司-年度观测。

财务数据取自三张 CSMAR 合并报表：资产负债表、利润表和现金流量表。只读取六个财务特征需要的字段，这样即使原始文件有几百兆，内存占用也还可以控制。年报文本来自巨潮信息披露网站。对每个公司-年度，我们下载对应披露年度的年报 PDF。

下载几千份 PDF 是最容易出现实际问题的地方，所以我们加了下载核对步骤。下载后，每个文件都会与样本清单核对，结果记录为可用、缺失或不匹配。本次运行的核对记录了 10,051 个可用公司-年度文件和 121 个缺失。缺失大多是该公司当年尚未上市或已经退市，因此属于数据可得性边界，而不是软件故障。

文本步骤用 pypdf 库从每个 PDF 里提取管理层讨论与分析（MD&A）部分。真实的 PDF 很乱：有些是扫描件，有些损坏，有些内部结构很特殊。因此提取被写成容错的。读不了的文件会被记为“pdf_error”状态并跳过，批处理继续处理下一个文件而不是停下来。进度每 25 个文件保存一次，所以如果机器中断，任务可以从上一个检查点继续，而不是从头开始。三个研究年份都按这个设计完成了提取。

4.3 特征工程

六个财务特征是：总资产收益率、资产负债率、营收增长率、经营现金流除以总资产、应收账款周转指标、总应计项除以总资产。这些是衡量盈利能力、杠杆、成长、现金流质量和盈余质量的常用指标。三个文本特征从 MD&A 文本计算：中文可读性、情感平衡和不确定性比率。情感和不确定性指标基于一个为中文金融语境准备的小词表，因为规模有限，我们把它称为引导词典。

建模前，应用两条预处理规则，避免少数极端值主导结果。第一，对数值在 1% 和 99% 分位做缩尾，也就是把最极端的值拉回到这些边界。第二，每个特征在其制造业子行业和年度组内做标准化，让公司只与同一年相似的公司在同一尺度上比较。当一组观测少于 20 个时，回退到在全样本上标准化。用相同的合格观测构建三个矩阵：仅财务矩阵、仅文本矩阵，以及包含全部九个特征的融合矩阵。使用相同观测让比较更公平。

4.4 模型开发

主模型是孤立森林（Isolation Forest）。思路很简单：异常观测更容易与其余数据分开，所以能用很少几次切分就分离出来的观测会得到更高的异常分数。我们把树的数量设为 500，每棵树用的样本数设为 256，随机种子设为 42。判定规则事先固定：当一个观测的分数落在样本前 10% 时就被标记。我们还检查前 5% 和前 15%，以确保主要结论不依赖于某一个特定阈值。

作为稳健性模型，我们训练一个自编码器（autoencoder），它是一个把特征压缩到小的中间层、再尝试重建原始特征的网络。重建误差（重建值与原始值的差）用作备选的异常分数：模型重建得不好的观测更不寻常。自编码器用 16、8、16 个单元的隐藏层、ReLU 激活函数和 Adam 优化器，并用与主模型相同的固定种子训练。

为了解释排序，我们使用 SHAP，这是一种被广泛使用、为每个特征分配对最终分数贡献的方法。我们报告三样东西：每个特征的整体重要性、财务组与文本组各自的合计重要性，以及排名最高观测的局部解释。这一步很重要，因为输出是为了辅助人工审查，审查者需要知道某个公司-年度为什么被排为异常。解释只说明模型的推理，本身并不证明任何公司有不当行为。

4.5 评估实现

评估与模型训练严格分离，避免基准泄漏进模型。我们从财务报表计算 Beneish M-Score（一个广为人知、基于会计指标度量可能盈余操纵的指标），只把它用作外部基准。然后用 Spearman 秩相关衡量异常分数与 M-Score 的一致程度。我们还计算前 10% 队列的事件率和富集率：事件率是高 M-Score 案例出现在队列中的频率，富集率把该频率与全样本中的频率做比较。

对第三个研究问题，我们比较仅财务、仅文本、融合和自编码器模型以及不同阈值产生的前列名单，衡量它们之间的重叠程度。重叠高说明排序稳定；重叠低说明结果对小的设计选择敏感。这个比较用同一张特征表计算，所以差异来自模型而不是来自不同的数据。

4.6 当前实现状态与局限

截至撰写时，样本构建、下载核对、三个年度的 MD&A 提取、质量控制报告和描述性统计脚本都已完成，并通过自动化测试验证（七十多个测试全部通过）。唯一剩下的输入依赖是 CSMAR 的利润表和现金流量表，这两张表还没有放到数据文件夹里。一旦这两个文件可用，就能运行财务特征表和完整实验，并把结果写进实验章节。本章描述的实现不需要改变。

主要局限如下。第一，中文文本词典是小的引导版本，所以情感和不确定性指标比完整的学术词典要粗糙。第二，PDF 提取会引入一些噪声，因为扫描页和不常见版式不一定总能被完美读取。第三，样本限于三年内的制造业公司，所以结果不应推广到其他行业或时期。由于这些局限，这个流程应该被理解为一种给人工审查排序公司先后顺序的工具，而不是证明某家公司确实存在欺诈或低质量披露的证据。